

交通标志检测与识别系统

基于 YOLOv8 的 GTSDb 交通标志检测

交通标志检测与识别系统

基于 YOLOv8 的 GTSDb 交通标志检测

摘要

本实验基于 YOLOv8 目标检测框架，针对德国交通标志检测基准数据集（GTSDb）实现了交通标志检测与识别系统。

德国交通标志检测基准（GTSDb）是一个广泛使用的公开数据集，包含 900 张标注图片（600 张训练、300 张测试），覆盖 43 类交通标志本

我们将 GTSDb 的 43 类细粒度标注映射为 5 个实际驾驶场景中最常见的类别：限速（speed_limit）、禁止通行（no_entry）、直行/转弯（direction）、人行横道（crosswalk）和停车让行（stop_yield）。实验采用 YOLOv8s 作为 baseline 模型，并通过强数据增强、余弦退火学习率调度和标签平滑等策略进行改进。最终模型在验证集上达到了 $mAP@0.5 = 0.9015$ ，满足 $mAP \geq 75\%$ 的要求。此外，我们还对不同场景条件（明亮、正常、低光、模糊）下的检测性能进行了对比分析，并对误检和漏检案例进行了深入分析。

关键词：交通标志检测；YOLOv8；GTSDb；目标检测；数据增强

一、引言

1.1 背景与意义

交通标志检测与识别是自动驾驶和高级辅助驾驶系统（ADAS）中的关键技术。准确的交通标志感知能够帮助车辆理解道路规则，做出安全合理的驾驶决策，对提升道路交通安全具有重要意义。在复杂多变的实际道路环境中，交通标志检测面临着光照变化、视角差异、遮挡、运动模糊等多重挑战。

1.2 数据集简介

德国交通标志检测基准（German Traffic Sign Detection Benchmark, GTSDb）是一个广泛使用的公开数据集，包含 900 张标注图片（600 张训练、300 张测试），覆盖 43 类交通标志。数据集场景涵盖城市道路、高速公路、乡村道路等多种环境，具有光照、天气和视角的多样性

二、实验方法

实验目标

本实验的主要目标包括：

- 基于 YOLOv8 实现交通标志的实时检测与识别
- 将 43 类细粒度标注映射为 5 个面向实际驾驶场景的核心类别
- 通过多种改进策略提升模型在不同场景条件下的检测性能
- 使用 mAP@0.5 作为主要评价指标，目标不低于 75%
- 系统分析误检和漏检案例，提出并验证改进策略
- 对不同场景条件(明亮、正常、低光、模糊)下的检测性能进行对比

2.1 数据集分析与预处理

2.1.1 数据集统计

GTSDb 数据集包含 900 张道路场景图片，每张图片可能包含多个交通标志。数据集中图片分辨率各异，交通标志在图片中的尺寸差异较大，小目标(面积 < 32×32 像素)占比较高，这增加了检测难度。

2.1.2 类别映射策略

原始标注为 43 类细粒度分类。由于部分类别样本极少(存在长尾分布问题)，且实际驾驶场景中对限速值、转弯方向等细节的区分属于后续分类任务，在不影响前端检测任务的前提下，我们按照以下规则将 43 类映射为 5 类:

目标类别	原始 GTSDb 类别 ID	描述	映射后样本数
speed_limit (0)	0,1,2,3,4,5,7,8	各 类 限 速 标 志 (30/50/60/80/100/120 等)	450 个实例
no_entry (1)	17	禁止通行	60 个实例
direction (2)	33,34,35,36,37,38,39	直行/转弯指示	120 个实例
crosswalk (3)	27	人行横道	50 个实例

stop_yield (4)	13.14	停车让行	80 个实例
----------------	-------	------	--------

这种映射策略的优势在于:语义统一，将细粒度分类统一为功能属性，降低检测难度；数据均衡，缓解了原始数据集中严重的类别不平衡问题；实际可用，更贴近实际驾驶场景中的感知需求。

2.1.3 数据划分

数据集按照 80:20 的比例随机划分为训练集和验证集。最终训练集包含 275 张图片，验证集包含 68 张图片。划分时采用分层抽样策略，确保各类别在训练集和验证集中的分布比例一致。

2.2 YOLOv8 模型架构

YOLOv8 是 Ultralytics 推出的单阶段目标检测模型，具有检测速度快、精度高的特点。本实验选用 YOLOv8s(small)版本，参数量约 11.2M，在精度和速度之间取得良好平衡。

YOLOv8 的核心架构包括:

- Backbone: CSPDarknet 结构,使用 C2f 模块替代了 YOLOv5 的 C3 模块。C2f 模块通过更多的跨层连接和更丰富的梯度流设计，在保持轻量化的同时提升了特征提取能力
- Neck: FPN + PAN 结构，通过自顶向下的特征金字塔和自底向上的路径聚合网络，实现多尺度特征融合，使模型能够同时检测大、中、小目标

- Head: 解耦检测头(Decoupled Head), 分别预测分类和回归任务。分类分支使用 BCE Loss, 回归分支使用 CIoU Loss + DFL Loss

与 YOLOv5 相比, YOLOv8 的主要改进包括:

1. 无锚框检测(Anchor-Free), 简化了检测头的设计
2. 解耦分类和回归头, 提升训练效率和检测精度
3. 新的损失函数设计, 回归分支引入 Distribution Focal Loss(DFL)
4. 更优的样本分配策略(Task-Aligned Assigner)

2.3 Baseline 训练配置

基线模型使用 YOLOv8s 预训练权重(在 COCO 数据集上预训练), 训练参数如下:

参数	值
输入尺寸	640×640
Batch Size	16
Epochs	100
优化器	SGD(momentum=0.937, weight_decay=0.0005)
初始学习率	0.01
最终学习率	0.001)
数据增强	默认增强(mosaic, HSV 抖动, 随机缩放等)
早停耐心	15 epochs
预热	3 epochs

标签平滑

0.0(baseline 不做)

2.4 改进策略

为提升模型在复杂场景下的鲁棒性，我们提出了以下改进策略：

2.4.1 强数据增强

增大 HSV 颜色抖动范围模拟不同光照条件，并增加几何变换范围提升对视角变化的鲁棒性：

增强类型	Baseline	Improved
HSV 色调抖动 (h)	0.015	0.05
HSV 饱和度抖动 (s)	0.7	0.7
HSV 明度抖动 (v)	0.4	0.5
旋转范围	0.0	±15.0
缩放范围	0.5	0.6
平移范围	0.1	0.15

2.4.2 Mosaic + MixUp + Copy-Paste 组合增强

- Mosaic 拼接:将 4 张训练图片随机拼接为一张，提升小目标检测能力，同时增加训练样本的多样性
- MixUp 混合:以一定比例混合两张图片及其标注，减少对训练样本的过拟合
- Copy-Paste 增强:将小目标复制粘贴到其他图片中，专门针对小目标检测困难的问题

2.4.3 余弦退火学习率调度

使用余弦退火调度(`cos_lr=True`), 学习率从 0.01 按照余弦曲线平滑衰减至 0.001。相比阶梯式衰减, 余弦退火的优势在于:学习率变化更加平滑, 有利于收敛到更优的局部极小值; 在训练后期以较低学习率进行精细调优; 无需手动设置衰减里程碑。

2.4.4 标签平滑

引入标签平滑 (`label_smoothing =0.05`), 将硬标签(0 或 1)替换为软标签(0.05/0.95), 防止模型产生过度自信的预测, 提升泛化能力。标签平滑正则化的效果等价于在损失函数中增加 KL 散度项。

2.4.5 预热 + 早停优化

- 预热阶段:5 个 epoch 的线性预热, 学习率从 0 逐步上升至 0.01, 避免模型在初始阶段因学习率过大而不稳定
- 早停机制:耐心值设为 30 个 epoch, 允许模型有更充分的时间收敛, 同时防止无效训练

2.5 改进策略

为提升模型在复杂场景下的鲁棒性, 我们提出了以下改进策略:

1. 强数据增强: 增大 HSV 颜色抖动范围 ($h=0.05, s=0.7, v=0.5$), 模拟不同光照条件;

增大几何变换范围 (旋转 $\pm 15^\circ$ 、缩放 0.6、平移 0.15), 提升对视角变化的鲁棒性

2. Mosaic + MixUp + Copy-Paste: 使用 Mosaic 拼接 (4 张图)、MixUp 混合和 Copy-Paste 增强, 特别针对小目标
3. 余弦退火学习率: 使用余弦退火调度 (`cos_lr=True`), 从 `lr0=0.01` 平滑衰减至 `lrf=0.001`
4. 标签平滑: `label_smoothing=0.05`, 防止模型过度自信, 提升泛化能力
5. 预热 + 早停: 5 个 epoch 预热, 30 个 epoch 早停耐心

三、实验结果

3.1 实验环境

硬件/软件	配置
GPU	NVIDIA RTX 3060 (12GB VRAM)
CPU	Intel Core i7-12700
内存	32GB DDR4
操作系统	Windows 11
深度学习框架	PyTorch 2.0.1
模型库	Ultralytics YOLOv8

3.2 模型性能对比


指标	Baseline	Improved	提升幅度
mAP@0.5	0.8685	0.9015	+3.3%
mAP@0.5:0.95	0.7211	0.7228	+0.2%
Precision	0.9370	0.9245	-1.3%
Recall	0.7901	0.8895	+9.9%
F1-Score	0.8573	0.9067	+4.9%

结果分析：


- 1、mAP@0.5 提升+3.3%: 改进模型从 0.8685 提升至 0.9015, 远超 75%的目标阈值, 说明改进策略有效提升了模型的整体检测精度
- 2、Recall 大幅提升+9.9%: 从 0.7901 提升至 0.8895, 这是本次改进最大的收获。Recall 的提升意味着模型能够检测出更多真实的交通标志, 大幅减少了漏检情况
- 3、Precision 轻微下降 -1.3%: 从 0.9370 小幅下降至 0.9245, 说明模型在检测到更多正样本的同时, 也略微增加了误检。这是 Recall-Precision 之间的固有权衡
- 4、F1-Score 提升+4.9%: 从 0.8573 提升至 0.9067, 综合证明了改进策略的有效性

5、mAP@0.5:0.95 仅提升+0.2%：该指标对预测框的定位精度要求较高，提升幅度较小说明定位精度的提升需要针对性优化

3.3 训练曲线分析



Lose_curve_baseline



Lose_curve_improved

训练损失曲线对比 (Baseline vs Improved)

从训练曲线可以观察到以下关键现象：


- 1、收敛速度：改进模型的分类损失和回归损失在训练初期下降更快，说明强数据增强提供的多样化训练样本有助于模型更快学习
- 2、收敛稳定性：改进模型的损失曲线波动更小，证明标签平滑和余弦退火学习率调度

有效稳定了训练过程

3、最终收敛：模型在约 50-60 epoch 后达到收敛状态，改进模型的最终训练损失和验证损失均低于基线模型

4、过拟合抑制：基线模型在约 70 epoch 后出现验证损失轻微上升的趋势，而改进模型由于数据增强和标签平滑的正则化效果，未观察到明显的过拟合现象

3.4 混淆矩阵分析



混淆矩阵显示各个类别的分类准确率分布。主要发现包括：

- 1、主干类别表现优异：`speed_limit` 作为样本最多的类别，分类准确率最高（约 95%），误报率最低
- 2、跨类别混淆：主要混淆发生在以下场景：
- 3、`speed_limit` ↔ `no_entry`：两者均为圆形红色标志，视觉特征相似，容易被混淆
- 4、`direction` ↔ `crosswalk`：部分方向指示标志含有白色图案，与斑马线的局部纹理存在相似性
- 5、类别不平衡影响：样本量较少的类别（如 `crosswalk`）的召回率相对较低，验证了数据增强中 Copy-Paste 策略对小样本类别的重要性
- 6、背景误检：部分背景区域被误检为交通标志，主要出现在含有圆形物体（如广告牌、

车灯) 的场景

3.5 不同场景条件对比

不同场景条件下的检测性能对比 (mAP@0.5)

场景	图片数	采样数	mAP@0.5	mAP@0.5:0.95	Precision	Recall
正常	68	50	0.867	0.733	0.919	0.802

我们根据图片的亮度和模糊度将验证集分为四类场景，各类场景的性能表现如下：

场景类型	图片数	mAP@0.5	特点分析
明亮条件	22	0.957	光照充足，标志清晰，检测性能最佳
正常条件	25	0.952	常规道路环境，性能接近明亮条件
低光条件 (夜间/黄昏)	12	0.878	光照不足，标志对比度下降，性能有所降低
模糊条件 (运动/失焦)	9	0.831	图像细节丢失，对检测影响最大

结果分析：

1、明亮和正常光照条件下，模型性能最优 ($mAP@0.5 \approx 0.95+$)，说明 YOLOv8s 在常规条件下具有强大的检测能力

2、低光条件下，性能下降至约 0.878 (降幅约 8%)，主要原因是：(1) 夜间标志与背景的对比度降低；(2) 车灯反光造成的局部过曝；(3) 标志表面反光导致颜色失真

3、模糊条件下，性能下降最为明显 ($mAP@0.5 = 0.831$ ，降幅约 13%)，直观反映了图像清晰度对目标检测的重要影响。模糊主要来源于：(1) 车辆运动造成的运动模糊；(2) 相机失焦；(3) 雨雪天气

4、改进模型在所有场景下均优于基线模型，尤其是在模糊场景下提升最为显著 (+5.2%)，说明改进策略中的强数据增强有效提升了模型的鲁棒性

3.6 误差与漏检分析

误检 / 漏检案例分析



我们对验证集样本进行了详细的误检/漏检分析，统计结果如下：

错误类型	出现次数	占比	主要原因
误检 (False Positive)	15	31.9%	背景中的圆形物体（广告牌、车灯）、纹理相似区域
漏检 (False Negative)	32	68.1%	小目标、遮挡、极端光照

误检案例分析

模型在复杂背景中将非交通标志物体误判为交通标志，主要出现在以下场景：

- 1、圆形广告牌/标志物：背景中与交通标志形状相似的圆形物体最具欺骗性
- 2、红色/蓝色区域：颜色特征与交通标志（尤其是限速和禁止标志）相近的区域
- 3、重复纹理：建筑物上的规则图案被误认为标志边缘特征

漏检案例分析

模型未能检测到实际存在的交通标志，主要原因包括：

- 1、小目标（远处标志）：占比最大的漏检原因，远处交通标志在图像中仅占据极少量像素，特征信息不足
- 2、遮挡：树枝、其他车辆、建筑物等对标志的部分遮挡
- 3、极端光照：背光、逆光或强反光导致标志表面细节不可辨
- 4、旋转/倾斜：非正视角下的交通标志呈现明显形变



改进建议



针对上述问题，我们提出以下改进策略：

- 1、多尺度训练：使用更高分辨率输入（如 1280×1280）或多尺度训练策略，增强小目标检测能力
- 2、困难样本挖掘：在训练集中增加更多遮挡和小目标样本，或使用在线困难样本挖掘（OHEM）
- 3、注意力机制：在 Backbone 中引入 CBAM 或 SE 注意力模块，增强对关键区域的关注
- 4、数据重采样：对低光、模糊等困难场景的样本进行过采样，提升模型在这些条件下的表现

3.7 交互可视化测试平台

为直观验证改进 YOLOv8 交通标志检测模型的泛化性能，搭建了交互式可视化系统，支持本地图片上传，后台模型推理，检测框与置信度可视化输出，实现模型检测效果在线可视化测试。







3.8 消融实验

为了验证各项改进策略的独立贡献，我们进行了消融实验：

配置	mAP@0.5	Recall	相对提升
Baseline	0.8685	0.7901	-
+ 强数据增强	0.8892	0.8587	+2.4%
+ MixUp + Copy-Paste	0.8961	0.8723	+3.2%
+ 余弦退火	0.8935	0.8688	+2.9%
+ 标签平滑	0.8756	0.8034	+0.8%
全部改进 (Improved)	0.9015	0.8895	+3.3%

消融实验表明：

- 1、强数据增强贡献最大（+2.4% mAP），说明数据多样性对模型泛化至关重要
- 2、MixUp + Copy-Paste 进一步提升了 Recall（+3.2%），特别对小目标检测有效
- 3、标签平滑单独贡献较小（+0.8%），但与其他策略结合时发挥协同作用
- 4、各项改进之间存在正向协同，组合使用时效果优于单独使用

四、结论

4.1 工作总结

本实验成功实现了基于 YOLOv8 的交通标志检测与识别系统，在 GTSDb 数据集上完成了 5 类交通标志的检测任务。

主要贡献包括：

- 1. 类别映射方案：设计了合理的 43→5 类别映射方案，将细粒度分类适配为实际驾驶场景中的核心类别，有效缓解了长尾分布问题。
- 2.改进策略体系：通过强数据增强（HSV 抖动、几何变换、MixUp、Copy-Paste）、余弦退火学习率、标签平滑和预热策略等多维度改进，有效提升了模型在不同场景下的鲁棒

性。

3.系统对比分析：对不同场景条件（明亮、正常、低光、模糊）下的检测性能进行了系统的消融实验和对比分析。

4.错误分析：深入分析了误检和漏检案例，揭示了模型在不同场景下的表现差异和局限性，为进一步改进提供了明确方向。

4.2 最终指标

最终模型在验证集上达到了以下关键指标：-mAP@0.5 = 0.9015 (Improved) , 远超课程要求的 75% 阈值 - F1-Score = 0.9067, 综合精度和召回率的平衡表现-Recall 从 0.7901 大幅提升至 0.8895 (+9.9%) , 验证了改进策略在有限数据场景下对漏检问题的显著改善效果。

4.3 未来工作

后续工作可以在以下方向继续深入：

1. 模型部署优化：将模型转换为 ONNX 格式，使用 TensorRT 进行推理加速，实现在嵌入式平台（如 NVIDIA Jetson）上的实时部署。

2. 视频流目标跟踪：在检测基础上集成 SORT / DeepSORT 跟踪算法，实现视频流中的稳定目标跟踪和时序一致性约束

3.类别扩展：恢复 43 类细粒度分类能力，通过多阶段检测+分类流水线或端到端多标签检测实现。

4.多模态融合：结合语义分割信息增强对道路场景的理解，在极端条件下提供更鲁棒的检测结果

5.模型轻量化：探索 YOLOv8n 或模型剪枝、量化等技术，在保持精度的同时进一步提升检测速度

